

Análisis Exploratorio de Datos (EDA) — Mercado Inmobiliario de Madrid

Identificación de variables críticas en la determinación del precio de venta mediante datos de Idealista.

Definición del Problema y Variables

Variables Objetivo (y): Precio de venta (buy_price).

Variables Independientes (x): Metros cuadrados (sq_mt_built), número de habitaciones (n_rooms), número de baños (n_bathrooms), ascensor (has_lift), estacionamiento, etc..

¿Cómo se plantea esta Prueba de Hipótesis?

Hipótesis Nula (H_0): $\rho = 0$. No existe una correlación lineal real en la población entre las variables `sq_mt_built`, `n_rooms`, `n_bathrooms` y el precio de venta(`buy_price`). Cualquier relación observada en la muestra es puro azar.

Hipótesis Alternativa (H_1): $\rho \neq 0$. Existe una correlación lineal significativa y real entre as variables `sq_mt_built`, `n_rooms`, `n_bathrooms` y el precio de venta.

Establecemos el nivel de significación estándar en $\alpha = 0.05$ (5% de margen de error tolerable). Si el p-valor obtenido es menor a 0.05, rechazamos la hipótesis nula.

Visión General del dataset

1.1 Visión general del dataset

```
# Data quality overview

print('=== Instantánea de la calidad de los datos ===')
quality = pd.DataFrame({
    'dtype': df_raw.dtypes,
    'non_null': df_raw.count(),
    'missing': df_raw.isnull().sum(),
    'missing_%': (df_raw.isnull().mean() * 100).round(1),
    'unique': df_raw.nunique(),
    'unique_%': (df_raw.nunique() / len(df_raw) * 100).round(1),
})
print(quality.to_string())
```

...

	dtype	non_null	missing	missing_%	unique	unique_%
Unnamed: 0	int64	21742	0	0.00	21742	100.00
id	int64	21742	0	0.00	21742	100.00
title	object	21742	0	0.00	10736	49.40
subtitle	object	21742	0	0.00	146	0.70
sq_mt_built	float64	21616	126	0.60	678	3.10
sq_mt_useful	float64	8228	13514	62.20	408	1.90
n_rooms	int64	21742	0	0.00	19	0.10
n_bathrooms	float64	21726	16	0.10	16	0.10
n_floors	float64	1437	20305	93.40	6	0.00

Visión General del dataset

Variable	Significado
<i>sq_mt_built</i>	m ² construidos
<i>n_rooms</i>	n.º de habitaciones
<i>sq_mt_useful</i>	m ² útiles
<i>n_bathrooms</i>	n.º de baños
<i>floor</i>	planta
<i>neighborhood_id</i>	ID del barrio
<i>buy_price</i>	Precio de compra
<i>house_type_id</i>	ID del tipo de vivienda
<i>is_renewal_needed</i>	¿Necesita renovación?
<i>is_new_development</i>	¿Es una construcción nueva?
<i>has_lift</i>	Tiene ascensor
<i>is_exterior</i>	Tiene exterior
<i>has_terrace</i>	Tiene terraza
<i>has_storage_room</i>	Tiene trastero
<i>has_parking</i>	Tiene aparcamiento

Variable	Significado
<i>sq_mt_allotment</i>	Superficie en metros cuadrados
<i>latitude</i>	latitud
<i>longitude</i>	longitud
<i>raw_address</i>	dirección_original
<i>is_exact_address_hidden</i>	dirección_exacta_oculta
<i>street_name</i>	nombre_calle
<i>street_number</i>	número_calle
<i>portal</i>	portal
<i>is_floor_under</i>	piso_bajo
<i>door</i>	puerta
<i>neighborhood_id</i>	identificador_barrio
<i>operation</i>	operación
<i>rent_price</i>	precio_alquiler
<i>rent_price_by_area</i>	precio_alquiler_por_área

Proceso de Limpieza de Datos (Data Wrangling)



Consistencia del Dataset: Dataset Original: **21,742 filas y 58 columnas.**

Estrategias de Calidad de Datos aplicadas:

- **Eliminación por nulos (100%):** Columnas sin ningún registro como `latitude`, `longitude`, `rent_price_by_area`, `portal` o `is_furnished` fueron dadas de baja de inmediato.
- **Eliminación por colinealidad/vacíos:** Se descartó `sq_mt_useful` (62.2% de nulos) para evitar redundancia y debilidad estadística frente a `sq_mt_built`.
- **Imputación de Criterio de Negocio:** En variables como `has_pool` o `has_ac`, la ausencia de dato se interpretó correctamente como la no disponibilidad del servicio (`False`), transformándose en flags booleanas completas.
- **Eliminación de Varianza Cero:** Columnas como `operation` y `is_buy_price_known` (con un único valor unívoco en las 21,742 filas) se eliminaron por no aportar variabilidad al modelo.


Análisis Univariante - La Variable Objetivo(Precio de Venta)

Variable objetivo: Precio de Venta





Análisis Univariante — Variables Relevantes

Análisis Univariado — Variables Independientes






Análisis Univariante — Variables Categóricas




Análisis de Correlación — Top Predictores del Precio



Análisis Bivariado — Scatter plots vs buy_price



Análisis de Correlación — Top Predictores del Precio




Análisis Bivariante — Precio vs. Tipología de Vivienda



Conclusiones y Recomendaciones de Negocio

Para validar el análisis estadístico, se realizaron pruebas de hipótesis de significación lineal (Pearson) con un nivel de confianza del 95% ($\alpha = 0.05$). En las variables **Metros Cuadrados**, **Número de Baños** y **Habitaciones**, los p-valores obtenidos fueron inferiores a 0.05, por lo que **se rechaza la Hipótesis Nula (H_0)** que afirmaba la ausencia de relación. Concluimos con total seguridad estadística que el tamaño y la distribución del inmueble son variables predictoras altamente significativas para estimar el **precio de venta** en Madrid.



Resumen Ejecutivo

RESUMEN EJECUTIVO — ANÁLISIS INMUEBLES MADRID

Dataset original: 21,742 inmuebles × 58 variables

Dataset procesado: 20,922 inmuebles × 24 variables

Variables objetivo:

buy_price — Mediana: 359,000 € | Media: 564,202 €

Top 3 variables predictoras (Spearman):

sq_mt_built r = 0.8328

n_bathrooms r = 0.7828

n_rooms r = 0.5415

Precio mediano por tipo:

Casa/Chalet 1,100,000 €

Áticos 595,000 €

Dúplex 465,000 €

Pisos 320,000 €

Distritos más caros (precio mediano):

Salamanca 795,000 €

Chamartín 750,000 €

Moncloa 750,000 €

Chamberí 699,000 €

Hortaleza 560,000 €

Gracias!